EPICODE

Python
GIORNO 6 – Pandas – Pulizia dei dati e gestione dei nulli

Agenda:

- ❏ Pandas - Pulizia dei dati
- ❏ Pandas - Gestione dei nulli

Perché?

- I dati puliti sono un'utopia. A causa di problematiche tecniche, strutturali, metodologiche e/o di errori umani è molto raro che i dati che riceviamo siano da subito puliti e completamente utilizzabili.

- Per poter portare avanti un'analisi significativa diventa necessario sapere come gestire i dati "sporchi" o nulli.

Alla fine di questa lezione saprete:

- ❏ Gestire i dati duplicati
- ❏ Utilizzare i metodi di Pandas per manipolare i dati testuali
- ❏ Gestire la pulizia delle date e dei dati numerici
- ❏ Le tipologie principali di dati nulli in Pandas
- ❏ Come gestire i valori nulli nelle situazioni più comuni

Data Cleaning

Il data cleaning è il processo di identificazione, correzione e eliminazione di errori, inconsistenze o dati incompleti all'interno di un set di dati al fine di migliorarne la qualità e l'affidabilità per l'analisi e l'elaborazione successiva.

Data Cleaning

I problemi che possiamo riscontrare in un set di dati sono vari e così anche i metodi per gestirli: per convenienza li raggruppiamo in base alla tipologia di dato a cui fanno riferimento e andiamo a vedere nel dettaglio come gestire:

- Righe duplicate
- Dati testuali
- Dati temporali
- Dati numerici
- Dati nulli

Righe duplicate

Può capitare di incontrare righe duplicate nel nostro set di dati. A volte può persino succedere che, in base alle operazioni che effettuiamo per processare i dati, siamo proprio noi a duplicare delle righe, o dei subset di esse.

Andiamo a creare un semplice DataFrame di esempio:

```
df = pd.DataFrame({"Studente": ["Andrea", "Maria", "Marco", "Silvia", "Andrea"],
                   "Corso": ["WebDev", "WebDev", "DataAnalysis", "CyberSecurity", "WebDev"]})
df
```

✓ 0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev
2	Marco	DataAnalysis
3	Silvia	CyberSecurity
4	Andrea	WebDev

Ad indice 0 ed indice 4 abbiamo una riga duplicata, cioè una riga che presenta gli stessi valori nelle stesse colonne.

Righe duplicate

Con un numero di righe così piccolo è facile trovare i duplicati anche ad occhio, ma come facciamo quando il numero di dati aumenta?
Possiamo utilizzare il metodo `.duplicated()` di Pandas:

```
df.duplicated()
✓ 0.0s
0    False
1    False
2    False
3    False
4     True
dtype: bool
```

Il metodo `.duplicated()` restituisce una Series in cui, per ogni indice del `DataFrame`, troviamo un valore booleano ad indicarci se la riga è già presente nel `DataFrame` stesso. Possiamo quindi usarla anche per filtrare:

```
df.loc[df.duplicated()]
✓ 0.0s
```

	Studente	Corso
4	Andrea	WebDev

Righe duplicate

Il metodo `.duplicated()` accetta due parametri:

- `subset=`: la colonna, o lista di colonne, su cui effettuare il controllo. Default: `None`
- `keep=`: quale delle righe segnare come duplicata. Può essere settato come `"first"`, `"last"` o `False`. Default: `"first"`

Righe duplicate

Per trovare i duplicati soltanto della colonna `"Corso"` utilizzeremo il parametro `subset=`:

```
df.loc[df.duplicated(subset="Corso")]
```

✓ 0.0s

	Studente	Corso
1	Maria	WebDev
4	Andrea	WebDev

In questo modo tutti a parte la prima occorrenza di ogni valore verranno segnati come duplicati.
Per marcare come duplicata anche la riga "originale" settiamo il parametro `keep=False`:

```
df.loc[df.duplicated(subset="Corso", keep=False)]
```

✓ 0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev
4	Andrea	WebDev

Se invece vogliamo che venga interpretata come riga "originale" l'ultima, settiamo `keep="last"`

```
df.loc[df.duplicated(subset="Corso", keep="last")]
```

✓ 0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev

Righe duplicate

Solitamente i duplicati si eliminano: Pandas ci viene in aiuto con il metodo `.drop_duplicates()`:

```
df
```
0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev
2	Marco	DataAnalysis
3	Silvia	CyberSecurity
4	Andrea	WebDev

```
df.drop_duplicates()
```
0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev
2	Marco	DataAnalysis
3	Silvia	CyberSecurity

```
df.drop_duplicates(subset="Corso")
```
0.0s

	Studente	Corso
0	Andrea	WebDev
2	Marco	DataAnalysis
3	Silvia	CyberSecurity

```
df.drop_duplicates(subset="Corso", keep=False)
```
0.0s

	Studente	Corso
2	Marco	DataAnalysis
3	Silvia	CyberSecurity

```
df.drop_duplicates(subset="Corso", keep="last")
```
0.0s

	Studente	Corso
2	Marco	DataAnalysis
3	Silvia	CyberSecurity
4	Andrea	WebDev

Righe duplicate

Come abbiamo visto `.drop_duplicates()` accetta gli stessi parametri di `.duplicated()`

Il metodo però non va ad aggiornare il `DataFrame` originale: se dopo aver fatto `.drop_duplicates()` andiamo a guardare ancora il nostro `DataFrame`, i dati sono ancora tutti lì:

```
df.drop_duplicates()
```
✓ 0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev
2	Marco	DataAnalysis
3	Silvia	CyberSecurity

```
df
```
✓ 0.0s

	Studente	Corso
0	Andrea	WebDev
1	Maria	WebDev
2	Marco	DataAnalysis
3	Silvia	CyberSecurity
4	Andrea	WebDev

Righe duplicate

Esistono due metodi per modificare il nostro DataFrame originale: il primo è quello di aggiungere come parametro `inplace=True`

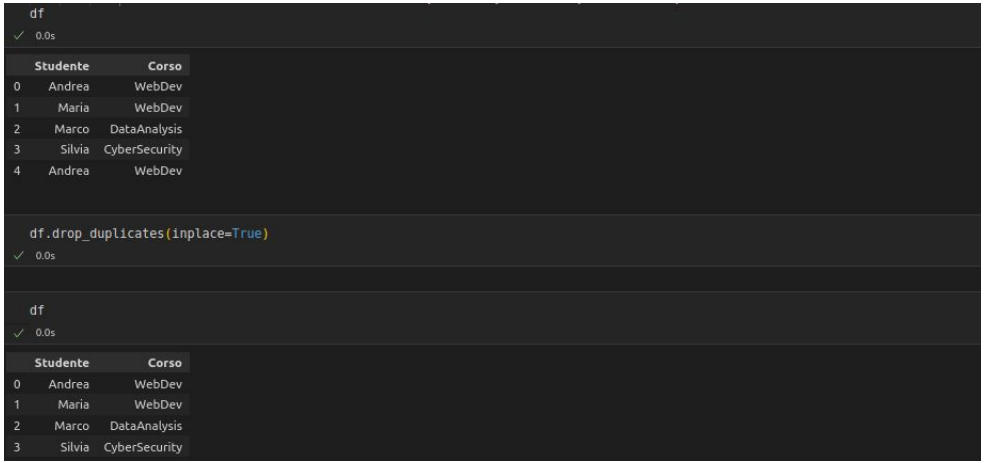

Questo metodo è fortemente sconsigliato per delle ragioni tecniche relative a come Python e Pandas gestiscono gli oggetti in memoria, al punto che Pandas ha in progetto di rimuoverlo gradualmente nelle prossime versioni.

Righe duplicate

Perché presentarvi un metodo sconsigliato? Perché se avrete a che fare con una codebase magari un po' datata, o scritta senza una profonda attenzione all'ottimizzazione, potrete incontrare questo parametro.
Come fare allora?
La best practice è: riassegnare alla stessa variabile il risultato del metodo `.drop_duplicates()`

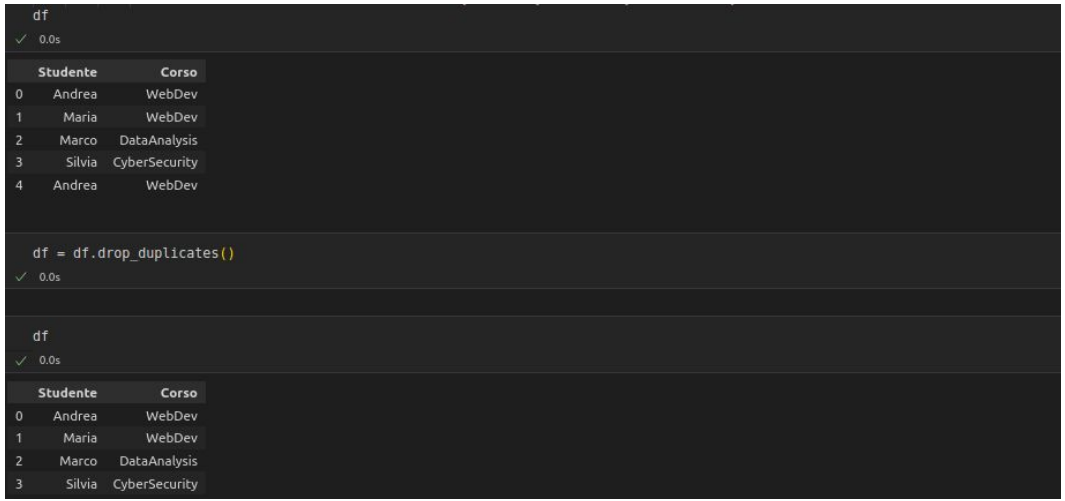

Best Practice

Questa pratica ci accompagnerà anche per tutti i prossimi metodi che modificano in qualche modo il `DataFrame`; questi **non rendono permanente la modifica**, ma restituiscono in output una versione diversa del `DataFrame`, oppure una `Series` se sono applicati ad una sola colonna o in generale se il risultato è monodimensionale.

Per memorizzare la nuova versione in output possiamo semplicemente assegnarla ad una nuova variabile, oppure se vogliamo rendere permanente la modifica possiamo sovrascrivere la variabile esistente.

Ricordiamoci sempre che la best practice è riassegnare alla stessa variabile, o ad una nuova, il risultato del metodo.

Se il metodo viene applicato ad una singola colonna, si può assegnare effettuando:

```
pandas.DataFrame["colonna"] = pandas.DataFrame["colonna"].metodo()
```

Dati testuali

Per andare ad agire sui dati testuali (cioè le stringhe), abbiamo una serie di metodi tra cui:

- `.str.upper()`, `.str.lower()`: Trasforma i caratteri in maiuscolo o minuscolo.
- `.str.strip()`, `.str.lstrip()`, `.str.rstrip()`: Rimuove gli spazi vuoti dall'inizio o dalla fine della stringa.
- `.str.split()`: Suddivide una stringa in base a un delimitatore specificato.
- `.str.contains()`: Restituisce una maschera booleana indicante se ogni stringa contiene un determinato pattern.
- `.str.replace()`: Sostituisce parte di una stringa con un'altra.
- `.str.extract()`: Estrae sottostringhe che corrispondono a un pattern specificato.

Dati testuali

Per fare degli esempi utilizzeremo il database "Titanic" che si trova sul server SQL della scuola, e che contiene una sola tabella, chiamata `titanic`.

Per accedervi dobbiamo modificare il nome del database nel file `.env`, modificando la riga:

```
dbname="Titanic"
```

oppure aggiungendone una nuova:

```
dbname2="Titanic"
```

Naturalmente in questo secondo caso nel nostro codice Python dovremo modificare la riga:

```
dbname = os.getenv("dbname2")
```

Una buona pratica, tuttavia, è quella di creare **cartelle diverse per ogni progetto** su cui si sta lavorando, e inserire un `.env` diverso in ognuno di essi che contiene i dati relativi **solo** al database specifico per quel progetto.

Questo permette di avere un ambiente di lavoro più ordinato che evita confusione tra i progetti.

.str.upper(), .str.lower()

Modifichiamo il case (maiuscolo o minuscolo) dei nomi dei passeggeri del Titanic:

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.5s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df["Name"] = df["Name"].str.upper()
df.head()
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	BRAUND, MR. OWEN HARRIS	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	CUMINGS, MRS. JOHN BRADLEY (FLORENCE BRIGGS TH...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	HEIKKINEN, MISS. LAINA	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	FUTRELLE, MRS. JACQUES HEATH (LILY MAY PEEL)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	ALLEN, MR. WILLIAM HENRY	male	35.0	0	0	373450	8.05		S	0	10-4-1912

.str.split()

Suddividiamo il nome di ogni passeggero in più elementi, specificando come pattern di separazione il carattere `","` (se non specifichiamo alcun pattern, il default è uno whitespace, `" "`) e creiamo una nuova colonna per la lista che ne risulta

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df["NameSplitted"] = df["Name"].str.split(pat=",")
df.head()
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate	NameSplitted
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912	[Braund, Mr. Owen Harris]
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912	[Cumings, Mrs. John Bradley (Florence Briggs ...
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912	[Heikkinen, Miss. Laina]
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912	[Futrelle, Mrs. Jacques Heath (Lily May Peel)]
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912	[Allen, Mr. William Henry]

Docs: https://pandas.pydata.org/docs/reference/api/pandas.Series.str.split.html

.str.contains()

il metodo `.str.contains()` restituisce una `Series` booleana, come il metodo `.duplicated()`
Proviamo ad usarlo per filtrare i nomi dei passeggeri che contengono la sottostringa `"Mr."`
Il parametro `regex=` è settato `True` di default. Se vogliamo che il nostro pattern voglia interpretato letteralmente e non come una regular expression, dobbiamo specificare `regex=False`

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df.loc[df["Name"].str.contains("Mr.", regex=False)]
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912
5	6	3	Moran, Mr. James	male	0.0	0	0	330877	8.46		Q	0	11-4-1912
6	7	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.86	E46	S	0	10-4-1912
12	13	3	Saundercock, Mr. William Henry	male	20.0	0	0	A/5. 2151	8.05		S	0	10-4-1912
...	...	...	...	...	...	...	...	...	...	...	...	...	...
1297	1298	2	Ware, Mr. William Jeffery	male	23.0	1	0	28666	10.50		S	0	10-4-1912
1298	1299	1	Widener, Mr. George Dunton	male	50.0	1	1	113503	211.50	C80	C	0	11-4-1912
1304	1305	3	Spector, Mr. Woolf	male	0.0	0	0	A.5. 3236	8.05		S	0	10-4-1912
1306	1307	3	Saether, Mr. Simon Sivertsen	male	38.5	0	0	SOTON/O.Q. 3101262	7.25		S	0	10-4-1912
1307	1308	3	Ware, Mr. Frederick	male	0.0	0	0	359309	8.05		S	0	10-4-1912

Docs: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.Series.str.contains.html

.str.replace()

Permette di sostituire una substringa con un valore.
Sostituiamo le occorrenze di `"Mr."` nei nomi dei passeggeri con `"Signor"`:

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df["Name"] = df["Name"].str.replace("Mr.", "Signor")
df
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Signor Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Signor William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912
...	...	...	...	...	...	...	...	...	...	...	...	...	...

.str.extract()

Estrae una sottostringa che corrisponde ad un pattern, che deve necessariamente essere una **regular expression**.
Restituisce un `DataFrame`; per avere una `Series` specifichiamo `expand=False`:

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df["Name"] = df["Name"].str.extract(r"(.*(?=,))", expand=False)
df
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen	male	35.0	0	0	373450	8.05		S	0	10-4-1912
...	...	...	...	...	...	...	...	...	...	...	...	...	...

Docs: https://pandas.pydata.org/docs/reference/api/pandas.Series.str.extract.html

Dati testuali - RegEx

Prima di vedere i metodi specifici di Pandas per manipolare i dati testuali, è necessario che introduciamo il concetto di **espressione regolare**

Quando ci troviamo a dover fare delle operazioni sulle stringhe di testo, le Regular Expression (in breve RegEx) permettono operazioni di ricerca e sostituzione e manipolazione dettagliate e approfondite.

Dati testuali - RegEx

Se ci viene presentato un testo qualsiasi, e ci viene richiesto di leggerlo e di identificare tutti i numeri di telefono al suo interno, oppure i codici fiscali, oppure tutti gli indirizzi email, siamo perfettamente in grado di farlo.

Come facciamo, visto che ovviamente contengono numeri o lettere diversi (telefono o CF), o addirittura possono essere di lunghezza diversa (email)?

Possiamo farlo perché hanno un **pattern specifico** che si può identificare, ad esempio per il CF:

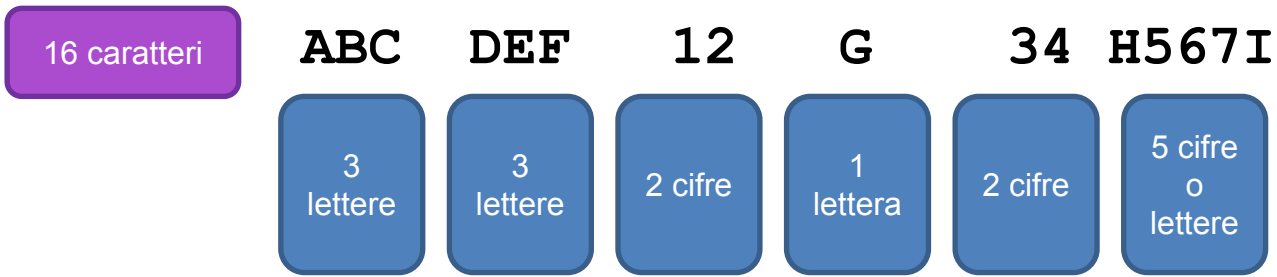

Dati testuali - RegEx

Per "spiegare" ad una macchina questi pattern possiamo usare le **Regular Expression** (RegEx o RegExp), che si presentano come stringhe di testo composte da caratteri e metacaratteri, dove i caratteri rappresentano sé stessi, mentre i metacaratteri sono caratteri che hanno un significato proprio e rappresentano classi di caratteri o comportamenti speciali.

La combinazione degli uni e degli altri ci permette di definire dei pattern da identificare all'interno di una stringa di testo.

Dati testuali - RegEx

Esempi di metacaratteri e sintassi RegEx:

`.`	un carattere qualsiasi
`\d`	un carattere alfanumerico (anche underscore)
`\w`	una cifra
`\s`	un carattere spazio (anche tab o newline)
`+`	il pattern precedente, ripetuto una o più volte
`*`	il pattern precedente, ripetuto zero o più volte
`?`	il pattern precedente può esserci oppure no
`{n, m}`	il pattern precedente ripetuto da n a m volte
`[]`	contengono un insieme di caratteri di interesse
`^`	inizio della riga
`$`	fine della riga
`-`	range di caratteri (da usare nelle parentesi quadre)

Dati testuali - RegEx

Regex: `ciao`

Riconosce il pattern:

✅ ciao
❌ miao

`[cm]iao`

✅ ciao
✅ miao
❌ iao
❌ kiao

`u.a`

✅ usa
✅ una
✅ u0a
✅ u#a
✅ usato (contiene il pattern)
❌ uffa (ci sono più di un carattere tra "u" e "a")
❌ ua (non ci sono caratteri tra "u" e "a")

Dati testuali - RegEx

`fatt?o`

✅ fatto
✅ fato
❌ favo
❌ fattto

`\d{3}`

✅ Blink 182
✅ La carica dei 101
✅ Nel 2005 è successo questo (esiste una sequenza di tre cifre)
❌ Ci sono 12 mesi
❌ La temperatura è di 9 gradi

`^[A-Z]`

✅ Ciao a tutti (c'è una lettera maiuscola ad inizio riga)
✅ Buongiorno (c'è una lettera maiuscola ad inizio riga)
❌ 1 Lettera (c'è una cifra ad inizio riga)
❌ salve (non c'è una lettera maiuscola ad inizio riga)

Dati testuali - RegEx

```
\d+
```

✅ Compra 3 pacchi di patatine
✅ Sono le 20:30
✅ Il budget è di $1000.00
❌ Compra tre pacchi di patatine
❌ Sono le venti e trenta

```
\w+@\w+\.[a-z]{2,3}
```

- `\w+` uno o più caratteri alfanumerici
- `@` una chiocciola
- `\.` un punto (letterale)
- `[a-z]{2,3}` due o tre lettere minuscole

✅ nomecognome@provider.com
✅ pinco_pallino@epicode.it
✅ user1234@sitoweb2.gov
❌ utente@@gmail.com (non c'è una sola chiocciola)
❌ nome@sitoweb.comm (l'estensione del provider ha 4 caratteri)

Dati testuali - RegEx

Esempio per il CF:

ABC	DEF	12	G	34	H567I
3 lettere	3 lettere	2 cifre	1 lettera	2 cifre	5 cifre o lettere
\w\w\w	\w\w\w	\d\d	\w	\d\d	\w

Oppure:

\w{3}	\w{3}	\d{2}	\w	\d{2}	\w

Poiché `\w` "cattura" anche le cifre; conoscendo i dettagli delle componenti di un CF, un modo ancora più preciso sarebbe:

[A-Z]{6}	\d{2}	[A-EHLMPR-T]	\d{2}	[A-Z0-9]{5}

Date

Per agire sulle date ci sono varie funzioni e metodi:

- `pd.to_datetime()`: converte una stringa di testo in un formato data
- `.dt.year`, `.dt.month`, `.dt.day`: estrarre una parte della data
- `.dt.dayofweek`, `.dt.dayofyear`: contestualizza la data

pd.to_datetime()

`pd.to_datetime()` è una funzione fondamentale. Molto spesso le date sono inserite o interpretate come stringhe, impedendoci di effettuare tutte le operazioni possibili/necessarie su questo speciale tipo di dato.

Usando `pd.to_datetime()` possiamo convertire le stringhe in formati data utilizzando vari parametri, tra cui i più importanti sono `dayfirst=` e `yearfirst=` che specificano come la stringa debba essere interpretata, in particolare in situazioni quali notazione anglosassone (mese/giorno/anno) o in situazioni ambigue (ad esempio 11/09/10).

Per tutti i parametri possibili, invece, riferiamoci alla documentazione di Pandas:
https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.to_datetime.html

pd.to_datetime()

Utilizziamo `pd.to_datetime()` per convertire la data di imbarco dei passeggeri da stringa a formato data; poiché le date sono ambigue (tutti i giorni sono <12) specifichiamo dayfirst=True:

```
query = "SELECT * FROM titanic"

df = pd.read_sql(query, db_engine)

db_engine.close()

df.loc[:, "EmbarkDate"] = pd.to_datetime(df.loc[:, "EmbarkDate"], dayfirst=True)
```

pd.to_datetime()

Nella visualizzazione non sembra cambiato molto, se non che ora l'anno e il mese vengono prima del giorno, ma se andiamo ad indagare la tipologia di dato tramite l'attributo `.dtype` vediamo che è cambiato, e passiamo da un `dtype('O')`, che sta per Object, che è come Pandas interpreta le stringhe o i dati misti, a un `dtype('<M8[ns]')`, che è un datatype specifico di NumPy per la gestione delle date.

.dt.year, .dt.month, .dt.day, .dt.dayofweek, .dt.dayofyear

Per estrarre delle parti specifiche della data, accediamo agli attributi del date object.
Estraiamoli dalla data di imbarco e assegniamoli a nuove colonne:

```
query = "SELECT * FROM titanic"
df = pd.read_sql(query, db_engine)
db_engine.close()

df.loc[:, "EmbarkDate"] = pd.to_datetime(df.loc[:, "EmbarkDate"], dayfirst=True)

df.loc[:, "Year"] = df.loc[:, "EmbarkDate"].dt.year

df.loc[:, "Month"] = df.loc[:, "EmbarkDate"].dt.month

df.loc[:, "Day"] = df.loc[:, "EmbarkDate"].dt.day

df.loc[:, "WeekDay"] = df.loc[:, "EmbarkDate"].dt.dayofweek  # 0: lunedì, 6: domenica

df.loc[:, "DayOfYear"] = df.loc[:, "EmbarkDate"].dt.dayofyear
```

Docs: https://pandas.pydata.org/pandas-docs/stable/reference/series.html#datetimelike-properties

Dati numerici

I principali metodi per pulire dati numerici sono:

- `.round()`: arrotonda i decimali di un float
- `.clip()`: stabilisce un limite massimo o minimo per i numeri

Sembrano pochi, ma questo è perché ai dati numerici si possono applicare tutte quelle funzioni base di Python e di NumPy che si occupano di gestire numeri e calcoli, quindi ci sono meno implementazioni specifiche legate a Pandas.

.round()

Usando `.round()` possiamo arrotondare un float, definendo quanti numeri dopo la virgola tenere. Ad esempio, arrotondiamo il costo del biglietto (contenuto nella colonna `"Fare"`) ad un solo numero decimale:

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df["Fare"] = df["Fare"].round(1)
df.head()
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.3	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0		S	0	10-4-1912

.clip()

Con `.clip()` possiamo delimitare il range dei nostri numeri, specificando un limite massimo e minimo tramite i parametri `upper=` e `lower=`.
Settiamo come limite massimo `55`, e come limite minimo `8`:

```
query = """SELECT * FROM titanic"""
df = pd.read_sql(query, db_engine)
df.head()
```

✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df["FareClipped"] = df["Fare"].clip(lower=8, upper=55)
df.head()
```

✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate	FareClipped
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912	8.00
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912	55.00
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912	8.00
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912	53.10
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912	8.05

Dati nulli

Un dato nullo è un'osservazione mancante o non disponibile, che può influenzare l'accuratezza e l'affidabilità delle analisi statistiche e dei modelli predittivi

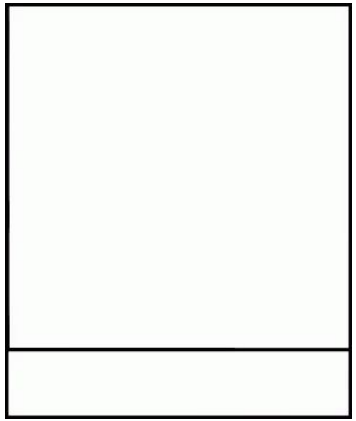

Dati nulli

In Pandas i dati nulli si possono presentare in modo esplicito e in modo implicito.

Quando i dati nulli sono espliciti, le celle sono riempite da valori `NaN` (Not a Number) o `NaT` (Not a Time), che sono datatype specifici di NumPy e Pandas, oppure attraverso dei `None` (il tipo di dato vuoto nativo di Python).

Quando i dati sono in questo formato, Pandas implementa tutta una serie di metodi per gestirli.

Quando i dati nulli sono invece impliciti abbiamo prima bisogno di convertirli in un valore che Pandas sappia interpretare come nullo. È esattamente il nostro caso, dove i dati nulli sono rappresentati da stringhe vuote.

Dati nulli

Vediamo infatti che, nonostante abbiamo delle celle vuote, il conteggio dei valori non nulli è uguale al numero delle righe del nostro DataFrame

```
df.head()
```
✓ 0.2s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	1	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.25		S	0	10-4-1912
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.28	C85	C	1	11-4-1912
2	3	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.93		S	1	10-4-1912
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	C123	S	1	10-4-1912
4	5	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.05		S	0	10-4-1912

```
df.info()
```
✓ 0.0s

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1309 entries, 0 to 1308
Data columns (total 13 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  1309 non-null   int64
 1   PClass       1309 non-null   int64
 2   Name         1309 non-null   object
 3   Sex          1309 non-null   object
 4   Age          1309 non-null   float64
 5   SibSp        1309 non-null   int64
 6   Parch        1309 non-null   int64
 7   Ticket       1309 non-null   object
 8   Fare         1309 non-null   float64
 9   Cabin        1309 non-null   object
 10  Embarked     1309 non-null   object
 11  Survived     1309 non-null   int64
 12  EmbarkDate   1309 non-null   object
dtypes: float64(2), int64(5), object(6)
memory usage: 133.1+ KB
```

Dati nulli

Andiamo a dare a questi dati nulli il formato tramite cui è più facile gestirli aiutandoci con `.replace()` e NumPy, e vediamo l'impatto su Non-Null Count:

```
import numpy as np

df = df.replace("", None)
df.info()
```

✓ 0.0s

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1309 entries, 0 to 1308
Data columns (total 13 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  1309 non-null   int64
 1   PClass       1309 non-null   int64
 2   Name         1309 non-null   object
 3   Sex          1309 non-null   object
 4   Age          1309 non-null   float64
 5   SibSp        1309 non-null   int64
 6   Parch        1309 non-null   int64
 7   Ticket       1309 non-null   object
 8   Fare         1309 non-null   float64
 9   Cabin        295 non-null    object
 10  Embarked     1307 non-null   object
 11  Survived     1309 non-null   int64
 12  EmbarkDate   1307 non-null   object
dtypes: float64(2), int64(5), object(6)
memory usage: 133.1+ KB
```

Dati nulli - .isna()

Un metodo per indagare i nulli, molto simile a quello dei duplicati, è `.isna()`, che restituisce una maschera, ovvero un `DataFrame` di booleani:

```
df.isna()
```
✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
0	False	False	False	False	False	False	False	False	False	True	False	False	False
1	False	False	False	False	False	False	False	False	False	False	False	False	False
2	False	False	False	False	False	False	False	False	False	True	False	False	False
3	False	False	False	False	False	False	False	False	False	False	False	False	False
4	False	False	False	False	False	False	False	False	False	True	False	False	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...

Possiamo applicarlo anche ad una colonna, e in quel caso possiamo usare la maschera per filtrare il `DataFrame`

```
df.loc[df["Embarked"].isna()]
```
✓ 0.0s

	PassengerId	PClass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	EmbarkDate
61	62	1	Icard, Miss. Amelie	female	38.0	0	0	113572	80.0	B28	NaN	1	NaN
829	830	1	Stone, Mrs. George Nelson (Martha Evelyn)	female	62.0	0	0	113572	80.0	B28	NaN	1	NaN

Dati nulli - .dropna()

Quando il numero dei dati nullo è molto basso rispetto alla totalità della base dati, possiamo semplicemente eliminare le righe. Ad esempio, abbiamo soltanto 2 righe su 1309 con dei valori nulli nella colonna `"Embarked"`, che rappresentano lo 0.15% del totale.
Pandas fornisce il metodo `.dropna()`, a cui possiamo specificare un subset di colonne.

```
df = df.dropna(subset="Embarked")
df.info()
```

✓ 0.0s

```
<class 'pandas.core.frame.DataFrame'>
Index: 1307 entries, 0 to 1308
Data columns (total 13 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  1307 non-null   int64
 1   PClass       1307 non-null   int64
 2   Name         1307 non-null   object
 3   Sex          1307 non-null   object
 4   Age          1307 non-null   float64
 5   SibSp        1307 non-null   int64
 6   Parch        1307 non-null   int64
 7   Ticket       1307 non-null   object
 8   Fare         1307 non-null   float64
 9   Cabin        293 non-null    object
 10  Embarked     1307 non-null   object
 11  Survived     1307 non-null   int64
 12  EmbarkDate   1307 non-null   object
dtypes: float64(2), int64(5), object(6)
memory usage: 143.0+ KB
```

Dati nulli

E i casi i dati nulli sono troppi per essere semplicemente eliminati?
La gestione dei dati nulli è un aspetto molto complesso, non esiste una soluzione unica ma bisogna valutare di caso in caso, a seconda dei dati che abbiamo a disposizione, quale strategia utilizzare.

Ad esempio: se ho dei nulli in una colonna numerica, posso rimpiazzarli con la media o la mediana dei valori di quella colonna. Ma può darsi che un dato mancante stia ad indicare uno 0, e quindi scegliendo un valore statistico andiamo ad inficiare la qualità del dataset.

Può darsi troviamo i dati mancanti da altre fonti, e possiamo in questo modo generare un dataset completo utilizzando dei `.merge()` o dei `.join()`, ma molto spesso questo non accade e dobbiamo necessariamente riempire i dati nulli facendo delle assunzioni.

Dati nulli

Dopo aver trovato la logica migliore per gestire i dati nulli, Pandas ci offre dei metodi per gestire i valori nulli tramite sostituzione. Questi metodi sono:

- `.fillna()`: Riempie i valori mancanti con un valore specificato
- `.dropna()`: Elimina righe o colonne che contengono valori mancanti
- `.interpolate()`: Effettua l'interpolazione dei valori mancanti utilizzando vari metodi come lineare, polinomiale, eccetera
- `.ffill()`: Sostituisce i valori mancanti con il valore precedente nella serie
- `.bfill()`: Sostituisce i valori mancanti con il valore successivo nella serie

Dati nulli

```
temp_data = pd.DataFrame({
    "day": [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12],
    "temperature": [20, 21, 22, None, 25, 25, None, 26, 27, 27, None, 30]
})
print(temp_data)
```

	day	temperature
0	1	20.0
1	2	21.0
2	3	22.0
3	4	NaN
4	5	25.0
5	6	25.0
6	7	NaN
7	8	26.0
8	9	27.0
9	10	27.0
10	11	NaN
11	12	30.0

Dati nulli

```
temp_data.fillna(0)
```

	day	temperature
0	1	20.0
1	2	21.0
2	3	22.0
3	4	0.0
4	5	25.0
5	6	25.0
6	7	0.0
7	8	26.0
8	9	27.0
9	10	27.0
10	11	0.0
11	12	30.0

Dati nulli

```
temp_data.fillna( temp_data.mean() )
```

	day	temperature
0	1	20.000000
1	2	21.000000
2	3	22.000000
3	4	24.777778
4	5	25.000000
5	6	25.000000
6	7	24.777778
7	8	26.000000
8	9	27.000000
9	10	27.000000
10	11	24.777778
11	12	30.000000

Dati nulli

```
temp_data.dropna()
```

	day	temperature
0	1	20.0
1	2	21.0
2	3	22.0
4	5	25.0
5	6	25.0
7	8	26.0
8	9	27.0
9	10	27.0
11	12	30.0

Dati nulli

```
temp_data.ffill()
```

	day	temperature
0	1	20.0
1	2	21.0
2	3	22.0
3	4	22.0
4	5	25.0
5	6	25.0
6	7	25.0
7	8	26.0
8	9	27.0
9	10	27.0
10	11	27.0
11	12	30.0

Dati nulli

```
temp_data.bfill()
```

	day	temperature
0	1	20.0
1	2	21.0
2	3	22.0
3	4	25.0
4	5	25.0
5	6	25.0
6	7	26.0
7	8	26.0
8	9	27.0
9	10	27.0
10	11	30.0
11	12	30.0

Dati nulli

```
temp_data.interpolate()
```

	day	temperature
0	1	20.0
1	2	21.0
2	3	22.0
3	4	23.5
4	5	25.0
5	6	25.0
6	7	25.5
7	8	26.0
8	9	27.0
9	10	27.0
10	11	28.5
11	12	30.0

EPICODE

GRAZIE

Epicode